

10 варіант

Для генерації 100 000 записів було використано бібліотеку Faker з угорською локаль("hu"), згідно з варіантом. Додано 3 власні атрибути: gender, subscription_tier, backup_email.

```
scratch.py  project.py ×  
arm  
1  import csv  
2  import uuid  
3  import random  
4  from faker import Faker  
5  
6  fake = Faker("hu")  
7  
8  num_records = 100_000  
9  filename = "fake_database.csv"  
10  
11  headers = [  
12      "unique_id", "person_name", "email", "personal_number", "birth_date",  
13      "address", "phone_number", "mac_address", "ip_address", "iban",  
14      "accessed_at", "session_duration", "download_speed", "upload_speed",  
15      "consumed_traffic", "gender", "subscription_tier", "backup_email"  
16  ]  
17  
18  with open(filename, mode='w', newline='', encoding='utf-8') as file:  
19      writer = csv.writer(file)  
20      writer.writerow(headers)  
21  
22      for _ in range(num_records):  
23          person_name = fake.name()  
24          safe_name = person_name.replace(_old: ' ', _new: '').lower()  
25          email = f"{safe_name}@{fake.free_email_domain()}"  
26          gender = random.choice(['Male', 'Female', 'Other'])  
27          backup_email = fake.ascii_safe_email()  
28          subscription_tier = random.choice(['Basic', 'Standard', 'Premium', 'Gigabit'])  
29  
30          writer.writerow([  
31              str(uuid.uuid4()),  
32              person_name,  
33              email,  
34              fake.ssn(),  
35              fake.date_of_birth(minimum_age=18, maximum_age=90),  
36              fake.address().replace(_old: "\n", _new: " ,"),  
37              fake.phone_number(),  
38              fake.mac_address(),  
39              fake.ipv4(),  
40              fake.iban(),  
41              fake.date_time_between(start_date="-1y"),  
42              random.randint(a: 0, b: 36_000),  
43              random.randint(a: 0, b: 1_000),  
44              random.randint(a: 0, b: 800),  
45              random.randint(a: 0, b: 2_000_000),  
46              gender,  
47              subscription_tier,  
48              backup_email  
49          ])  
50  
51  print(f"Успішно згенеровано {num_records} записів (Угорська локаль) у файл {filename}")
```

Створення Bronze Layer


Створено схему bronze_layer та денормалізовану таблицю fake_database (1NF).

Проблема 1: При спробі імпорту через інтерфейс pgAdmin виникла помилка.

Рішення: Використано SQL-команду COPY з явним зазначенням кодування UTF8 та CSV HEADER.

Проблема 2: Помилка Permission denied при COPY AS PATH з папки комп'ютера, де містяться проекти PyCharm .

Рішення: Файл переміщено до C:\Users\Public, що дозволило PostgreSQL отримати доступ на читання.



```
Query  Query History
1  DROP TABLE IF EXISTS bronze_layer.fake_database;
2
3  CREATE TABLE bronze_layer.fake_database (
4      unique_id UUID PRIMARY KEY,
5      person_name VARCHAR(255),
6      email VARCHAR(255),
7      personal_number VARCHAR(255),
8      birth_date DATE,
9      address TEXT,
10     phone_number VARCHAR(255),
11     mac_address VARCHAR(255),
12     ip_address VARCHAR(255),
13     iban VARCHAR(255),
14     accessed_at TIMESTAMP,
15     session_duration INT,
16     download_speed INT,
17     upload_speed INT,
18     consumed_traffic INT,
19     gender VARCHAR(50),
20     subscription_tier VARCHAR(50),
21     backup_email VARCHAR(255)
22 );
23 COPY bronze_layer.fake_database
24 FROM 'C:\Users\Public\fake_database.csv'
25 DELIMITER ','
26 CSV HEADER
27 ENCODING 'UTF8';
28
```

Query: `SELECT * FROM bronze_layer.fake_database LIMIT 10;`

	unique_id [PK] uuid	person_name character varying (255)	email character varying (255)	personal_number character varying (255)	birth_date date	address text	phone_number character varying (255)	mac_address character varying (255)	ip_address character varying (255)	token character varying (255)
1	84972a19-2e0b-492c-ae64-636107f291...	Prof. Dr. G. Borbély István	prof.dr.g.borbelyistvan@gmail.com	190110601310	1959-03-30	Mozsonmelléki utca 220., H-4794 Dunaújváros	06-6/189 5491	4a52:05:18:31:6c	193.132.7.101	G852AES486F
2	18c264e4-9890-4cce-9074-4d2dc7f9e...	D. Szabó László	d.szabolaszlo@yahoo.com	14308279953	1992-09-26	Mártonhídi utca 110., H-5065 Cegléd	94/849 6853	a2f5:43:eb:f4:ef	108.194.192.27	G843VSV7037
3	375e17e3-6b06-4c0e-a3f1-09db21bc00...	Farkas D. Ágnes	farkas.d.agnes@gmail.com	26401284411	2005-11-28	Székvárosi utca 97., H-2900 Mezőmártonváros	(06)00/130-7248	c43a:1e:0b:47:e0	96.225.215.124	G828XZW89064
4	36e1052b-3445-458d-8b0b-76cc1ca5dd...	Vargáné Dr. Tóth Ilona	varganedr.tothilona@gmail.com	26608167163	1966-03-10	Salgótarjáni utca 36., H-1795 Szeged	+36 09 759-9497	7a15:e6:84:56:07	142.69.8.155	G896GZBM0806
5	041484df-24f1-44e8-b559-14872bcc20...	Balogh T. Mária	balogh.t.maria@hotmail.com	17204286513	1969-10-27	Dunakeszi utca 249., H-3644 Budapestlakóv...	86/402 8833	b413:2c:c4:a0:2f	173.126.90.77	G8370EDW5183
6	64069f81-5673-4528-ac5f-48de68f181d	Szűcs Horváth Erzsébet	szucs.horvath.erzsebet@yahoo.com	180111243110	2004-08-22	Nagykanizsai út 144., H-7044 Szekszárd	06-35/516 0094	6e8d:cf:93:e6:26	56.188.215.105	G83SPADC7904
7	f580b436-305f-4a0a-9c48-9744aa9736...	Dr. Kissné Balázs Irén	dr.kissnabalazsireni@yahoo.com	28512017664	1953-11-26	Nyékmezői utca 223., H-3506 Témisfa	06-8/428 4391	b43a:dd:df:11:4d	13.21.166.103	G841XPTM2347
8	35e504af-fa48-4330-a589-52ace0d02d55	Kissné Kovács Vándora	kissnadovacs.vandora@hotmail.com	14705168432	1959-12-04	Bakonyszéki utca 116., H-2490 Dunaújváros	06-94/373 8573	2e2f:78:a3:96:80	24.46.68.211	G85SUEXN5367
9	5302be47-4a7b-43b6-a8a6-fc1bd0368a...	Dr. Szabóné Bró Mária	dr.szabonebro.maria@yahoo.com	11703054535	1990-05-10	Hajólapfalcai utca 75., H-8801 Baja	(06)163-4734	3480:47:5c:b6:92	213.6.123.40	G877CJQ04175
10	85e9371e-43aa-406d-91c4-65314e82d8...	Vargáné Tóth Katalin Judit	varganedothkatalinjudit@hotmail.c...	173050454010	1973-05-06	Felsőszéki utca 66., H-7071 Péladondevcsér	60/451-2199	2c08:30:e7:49:40	218.7.149.6	G884ICUW5279

Проектування Silver Layer

```

1  DROP SCHEMA IF EXISTS silver_layer CASCADE;
2  CREATE SCHEMA silver_layer;
3
4  CREATE TABLE silver_layer.dim_customer AS
5  SELECT DISTINCT ON (email)
6      MD5(email)::UUID AS customer_id,
7      person_name,
8      email,
9      personal_number,
10     birth_date,
11     phone_number,
12     gender,
13     backup_email
14 FROM bronze_layer.fake_database
15 WHERE email IS NOT NULL AND person_name IS NOT NULL;
16
17 ALTER TABLE silver_layer.dim_customer ADD PRIMARY KEY (customer_id);
18
19 CREATE TABLE silver_layer.dim_address AS
20 SELECT DISTINCT ON (address)
21     MD5(address)::UUID AS address_id,
22     address
23 FROM bronze_layer.fake_database
24 WHERE address IS NOT NULL;
25
26 ALTER TABLE silver_layer.dim_address ADD PRIMARY KEY (address_id);
27

```

```

CREATE TABLE silver_layer.dim_customer AS
SELECT DISTINCT ON (personal_number)
    MD5(personal_number)::UUID AS customer_id,
    person_name,
    email,
    personal_number,
    birth_date,
    phone_number,
    gender,
    backup_email
FROM bronze_layer.fake_database
WHERE personal_number IS NOT NULL;

ALTER TABLE silver_layer.dim_customer ADD PRIMARY KEY (customer_id);

CREATE TABLE silver_layer.fact_sessions AS
SELECT
    unique_id AS session_id,
    MD5(personal_number)::UUID AS customer_id,
    MD5(address)::UUID AS address_id,
    MD5(mac_address || ip_address)::UUID AS network_id,
    iban,
    subscription_tier,
    accessed_at,
    session_duration,
    download_speed,
    upload_speed,
    consumed_traffic
FROM bronze_layer.fake_database
WHERE session_duration > 0;

```

Дані приведено до 3NF за методологією Star Schema. Створено 3 таблиці вимірів (dim_customer, dim_address, dim_network) та 1 таблицю фактів (fact_sessions).

Проблема 3: Помилка Key is duplicated при створенні Primary Key для dim_customer. Генератор створив однакові email для різних рядків.

Рішення: Замість SELECT DISTINCT застосовано SELECT DISTINCT ON (email) для жорсткого усунення дублікатів і забезпечення унікальності первинних ключів. Щоб уникнути втрати даних через випадкові збіги email-адрес, генерацію customer_id було змінено. Тепер ключ базується на personal_number, що є надійнішим способом гарантувати унікальність кожного користувача.

Query		Query History													
1	SELECT * FROM silver_layer.dim_customer LIMIT 10;														

Query

Query History

1

SELECT * FROM silver_layer.fact_sessions LIMIT 10;

Data Output

Messages

Notifications

Showing rows: 1 to 10

Page No: 1 of 1

	session_id [PK] uuid	customer_id uuid	address_id uuid	network_id uuid	iban character varying (255)	subscription_tier character varying (50)	accessed_at timestamp without time zone
1	84972a15-2ed6-492c-ae4a-5361d7f291...	9e6c0eda-c914-b4a9-0077-72c2677b6...	a6d81d76-07f0-7642-29ee-7f6479ffb2...	d4941165-22a5-781e-92ce-925e77204...	GB52AESS486796005212...	Premium	2025-10-05 22:08:2...
2	18d26d4a-9890-4cce-9074-4d2ddc7f8e...	3fd3feb3-a6ca-34fe-93d9-cdc414d542...	c0f232aa-c676-9a97-c382-0898238f1e...	c05b7511-f786-cb38-8612-2deeb6baeb...	GB43VVS703788941949...	Gigabit	2025-08-06 02:38:1...
3	375e17e3-6bd6-4c0e-a3f1-09db21bc00...	d8e0caf2-c7c4-d08c-f5f4-f8c73765828c	70df1c34-a684-dd8f-7d40-85fe4ecd1a...	08416838-f75f-dc7b-6c04-50ff46b900b3	GB28XZW890647574758...	Gigabit	2025-10-21 01:16:3...
4	36e1052b-3445-458d-8b08-76cc1ca55d...	2f0252a1-d7c5-1349-1960-e7359ed23f...	f01a05ca-1ff3-91a9-aaff-add79e9028c7	4ac29723-c691-1e3f-170f-ff57d09f1cfe	GB96GZBM58068029131...	Premium	2026-01-11 09:43:3...
5	041484df-24f1-44e8-b559-14872bcc20...	4da24651-ee2d-8d1d-7f00-fca0b917c9...	fd93a575-ab5c-c56f-d790-190c0c65c8...	0e447bab-d844-e3ef-c7f4-b36a49277d...	GB37OEGW51831643154...	Premium	2026-01-24 02:32:0...
6	d4069f81-f673-4528-ac5f-48de685f181d	242be215-dc90-1cd7-743b-6e3b3fbc3...	9852fb4d-9cf4-d20b-b02b-3fff500e1a0e	2cd80cbf-1826-6672-8626-f82c351d0a...	GB35PADC790498283298...	Basic	2025-07-31 08:53:5...
7	f580b436-305f-4a0a-9c48-974aa97368c	f4e76033-3cc5-7675-602d-bbd222439...	e1943f0c-d816-4659-5c55-8030fe499b...	27055a7f-647b-0fd1-6160-b9076ada35...	GB41XPTM23475069877...	Premium	2025-10-14 19:49:0...
8	35e504af-bfa8-4330-a589-52ace0d02d55	06ad0c72-c284-c698-0c62-3ae94d5b5...	19188960-4b90-a3bc-3bb3-eadf46cea...	2e41b61d-da7e-4853-2314-777c998d3...	GB55UJXN36792638837...	Standard	2025-09-05 11:28:4...
9	5303eb47-4a78-43e6-aba6-fe1bcd369a...	1386ecd-d321-5282-aa07-34afe3339...	34fb82c8-b62f-31b6-acdb-f895546904...	a23bcd73-4058-9f2e-2a37-51cf8bc2a21f	GB77CJQQ417559202485...	Premium	2026-03-24 16:55:3...
10	85d9371a-43aa-406d-91c4-65314e82d8...	8120191b-5b44-f926-6a1b-8bf15776c4...	af93c970-632a-c31e-613b-d2428777f1...	d6574df8-d044-44ba-92ce-380143de4a...	GB84ICUW527906702894...	Basic	2025-08-26 08:46:0...

Проектування Golden Layer

```

DROP SCHEMA IF EXISTS golden_layer CASCADE;
CREATE SCHEMA golden_layer;

CREATE TABLE golden_layer.payment_data AS
SELECT
    f.customer_id AS non_pii_user_id,
    f.iban,
    f.download_speed,
    f.upload_speed,
    f.consumed_traffic,
    f.session_duration,
    ((f.download_speed + f.upload_speed) / 2.0) + (f.consumed_traffic::FLOAT / NULLIF(f.session_duration, 0)) AS payment_bill
FROM silver_layer.fact_sessions f;

CREATE TABLE golden_layer.technical_data AS
SELECT
    f.session_id AS unique_id,
    a.address,
    n.mac_address,
    n.ip_address,
    f.download_speed,
    f.upload_speed,
    ROUND(f.session_duration / 60.0, 2) AS session_duration_minutes,
    (f.download_speed + f.upload_speed) / 2.0 AS average_speed,
    (f.download_speed < 50 AND f.upload_speed < 30) AS technical_issue
FROM silver_layer.fact_sessions f
JOIN silver_layer.dim_address a ON f.address_id = a.address_id
JOIN silver_layer.dim_network n ON f.network_id = n.network_id;

CREATE TABLE golden_layer.pii_data AS
SELECT
    f.session_id AS unique_id,
    c.person_name,
    c.email,
    c.personal_number,
    c.birth_date,
    a.address,
    c.phone_number,
    n.mac_address,
    n.ip_address,
    f.iban,
    f.accessed_at,
    f.session_duration,
    f.download_speed,
    f.upload_speed,
    f.consumed_traffic
FROM silver_layer.fact_sessions f
JOIN silver_layer.dim_customer c ON f.customer_id = c.customer_id
JOIN silver_layer.dim_address a ON f.address_id = a.address_id
JOIN silver_layer.dim_network n ON f.network_id = n.network_id;

CREATE TABLE golden_layer.non_pii_data AS
SELECT
    f.session_id AS unique_id,
    CONCAT('*****', SUBSTRING(c.person_name FROM 6)) AS user_name_masked,
    CONCAT('*****', SUBSTRING(c.email FROM 6)) AS email_masked,
    CONCAT('*****', SUBSTRING(n.mac_address FROM 6)) AS mac_address_masked,
    CONCAT('*****', SUBSTRING(n.ip_address FROM 6)) AS ip_address_masked,

```

Створено 4 Data Marts . Обчислені нові метрики (наприклад, payment_bill та technical_issue), а також застосовано маскування чутливих даних (PII).

- Payment Data (Фінансовий Департамент)
- Technical Data (Технічна підтримка)
- PII Data (Вище керівництво)
- Non-PII Data (Рядові працівники)

✓ Successfully run. Total query runtime: 04 msec, 10 rows effected

Query

Query History

1

SELECT * FROM golden_layer.non_pii_data LIMIT 10;

Data Output

Messages

Notifications

</

Query

Query History

1

SELECT * FROM golden_layer.p11_data LIMIT 10;

Data Output

Messages

Notifications

</

Query

Query History

1


SELECT * FROM golden_layer.payment_data LIMIT 10;

Data Output

Messages

Notifications

RSD



Bronze Layer

Таблиця сирих даних `fake_database` відповідає вимогам 1NF. Всі атрибути містять атомарні значення (наприклад, ім'я, email, IP-адреса, швидкість зберігаються в окремих неподільних стовпцях). Проте в таблиці не усунуті часткові та транзитивні залежності. Наприклад, персональні дані клієнта (ім'я, email) та його адреса дублюються для кожної окремої інтернет-сесії. Оскільки це Landing Zone, наявність денормалізованих даних тут є архітектурно обґрунтованою.

Silver Layer

На цьому етапі дані були нормалізовані до 3NF за методологією Star Schema.

Таблиці вимірів (Dimensions): `silver_dim_customer` (клієнти), `silver_dim_address` (адреси), `silver_dim_network` (обладнання). Це унікальні довідники, очищені від дублікатів. Кожен з яких має свій унікальний ідентифікатор (Primary Key)

Усунення дублікатів та залежностей: Дані розділено на незалежні сутності, щоб усунути транзитивні залежності. Жодний неключовий атрибут більше не залежить від іншого неключового атрибута.

Таблиця фактів (Fact): Центральна таблиця `fact_sessions` містить лише метрики сесій та Foreign Keys, які посилаються на відповідні таблиці вимірів.

Зв'язки на діаграмі: Чорні лінії з розгалуженнями на кінцях означають зв'язок 1:N. Наприклад: один клієнт із таблиці `dim_customer` може мати багато інтернет-сесій у таблиці `fact_sessions`. Це позначається через зовнішні ключі FK.

Golden Layer

Для побудови Data Marts була застосована **свідома денормалізація**. Замість того, щоб змушувати BI-системи щоразу робити складні для сервера запити з багатьма JOIN, можна зібрати дані у плоскі таблиці, які читаються миттєво.

Кожна таблиця ізольована і створена під потреби конкретного відділу. Наприклад, технічний відділ (`technical_data`) бачить лише IP-адреси та середню швидкість, фінансовий (`payment_data`) — лише рахунки до оплати, а рядові працівники (`non_pii_data`) бачать замасковані зірочками персональні дані клієнтів.

Пріоритетом є швидкість читання даних, а не економія місця на диску. Дані з нормалізованих таблиць Silver-шару були об'єднані (через JOIN) у таблиці, ізольовані під потреби конкретних департаментів. Крім того, на цьому етапі:

- Обчислено нові метрики (наприклад, `payment_bill` та `average_speed`).
- Реалізовано розмежування доступу та маскування чутливої персональної інформації (PII) для таблиці `non_pii_data`.